

# Sistem Klarifikasi Bahasa Isyarat Indonesia (Bisindo) Dengan Menggunakan Algoritma Convolutional Neural Network

Lukman Arisandi  
Program Studi Informatika, Fakultas Ilmu  
Komputer,  
Universitas Amikom Yogyakarta  
Yogyakarta, Indonesia  
klukman.arisandi@students.amikom.ac.id

Barka Satya  
Program Studi Diploma III Teknik Informatika, Fakultas  
Ilmu Komputer  
Universitas Amikom Yogyakarta  
Yogyakarta, Indonesia  
barka.satya@amikom.ac.id

**Abstract**— Communication is needed to interact and socialize in order to connect with the environment and other people. In general, communication uses spoken or written words. However, in some cases in the community there are some people who cannot communicate verbally due to physical limitations such as deaf and speech impaired. Usually, they use nonverbal communication such as body movements and this communication is commonly referred to as sign language. The sign language method is used to spell or pronounce words. However, not everyone can understand the sign language used by the deaf and mute, so a system or tool is needed to bridge communication between the deaf or mute and normal people. One solution that can be offered is the use of computer technology as a tool to identify sign language. The technology is in the form of an automatic language translator system design with processing input images in the form of letter classes A to E, I, You and I Love You using the Convolutional Neural Network (CNN) architecture which by using this method the accuracy value can reach 99.82%.

**Keywords**— Sign Language, BISINDO, Convolutional Neural Network, Communication, deaf, speech impaired

## I. PENDAHULUAN

Komunikasi merupakan suatu proses sosial yang sangat dasar di mana seseorang atau beberapa orang, baik di organisasi maupun di masyarakat menyampaikan suatu informasi agar dapat terhubung dengan lingkungan dan orang lain[1]. Secara umum komunikasi dilakukan dengan kata-kata lisan atau tulisan, Namun di beberapa kasus ada sebagian orang yang tidak dapat berkomunikasi secara verbal dikarenakan keterbatasan fisik seperti tunarungu dan tunawicara. Biasanya mereka menggunakan komunikasi nonverbal seperti gerak-gerik tubuh baik menggunakan tangan ataupun anggota badan yang lain[2], komunikasi ini biasa di sebut dengan bahasa isyarat.

Namun menghadapi kendala bahwa tidak semua orang dapat memahami bahasa isyarat yang di gunakan oleh penyandang tunarungu dan tunawicara, sehingga mereka mendapat masalah ketika penyandang tunarungu dan tunawicara berkomunikasi dengan orang normal yang sebagian besar tidak memiliki pengetahuan tentang bahasa isyarat.

Berdasarkan data yang bersumber dari Sistem Informasi Manajemen Penyandang Disabilitas Kementerian Kesehatan Republik Indonesia pada Maret 2022 penyandang disabilitas di Indonesia berjumlah 212.240 jiwa, jumlah tersebut meningkat selama 2 tahun terakhir di mana pada Maret 2020 sebesar 197.582 jiwa dan Maret 2021 sebesar 207.604 jiwa, sedangkan untuk penyandang disabilitas tunawicara-rungu pada Maret 2022 berjumlah 19.392 atau 9.14% dari jumlah seluruh penyandang disabilitas di Indonesia[3].

Di Indonesia sendiri ada dua macam penggunaan bahasa isyarat yaitu Sistem Bahasa Isyarat Indonesia (SIBI) yang dibakukan dan diambil dari *American Sign Language* (ASL) dengan di tambah imbuhan awal dan akhir[4] dan Bahasa Isyarat Indonesia (BISINDO) yang merupakan bahasa ibu atau bahasa awal tunawicara-rungu yang di pakai sehari-hari[5].

BISINDO merupakan satu dari dua bahasa isyarat yang di gunakan di Indonesia selain SIBI. Bisindo sendiri diresmikan pada Kongres Nasional keenam Gerkatin di Bali tahun 2002 dengan tujuan mempertahankan bahasa isyarat alami[6].

Huruf abjad pada BISINDO berjumlah 26 karakter serta terdiri dari A sampai Z yang dapat dibentuk dengan satu tangan berupa huruf C, E, I, J, L, O, R, U, V dan Z dan huruf yang dapat di bentuk dengan dua tangan adalah A, B, D, F, G, H, K, M, N, P, Q, S, T, W, X dan Y, Seperti yang ditunjukkan pada Gambar. 1.



Gambar 1. Alfabet di BISINDO (Illustrator : Erwinsyah[7])

Penelitian yang dilakukan oleh Rohmah Ageng Mursita pada tahun 2015 terhadap 100 responden tunarungu usia remaja dan dewasa (16-50 tahun) menunjukkan bahwa 91% mayoritas tunarungu di Indonesia lebih memilih BISINDO dalam komunikasi sehari-hari, sedangkan hanya 9% yang menggunakan SIBI[8]. Penelitian ini hanya akan menggunakan salah satu bahasa isyarat yaitu BISINDO dengan model masukan akan juga menggunakan dataset BISINDO yang terdiri dari Sembilan kelas yaitu Huruf A-E, L, Saya, Kamu dan I Love You.

Dalam perkembangannya, penelitian dengan pembahasan *hand motion* dan *hand gesture detection* menjadi semakin banyak dan populer, sebagaimana penelitian terkait yang dilakukan oleh Jie Huang, Wengang Zhou, Houqiang Li, and Weiping Li di tahun 2019 dengan judul “Attention-Based 3D-CNNs for Large-Vocabulary Sign Language Recognition”. Penelitian ini di publikasikan di IEEE Volume 29 No. 9 Pages 2822 – 2832. Dalam penelitian ini membahas tentang Pengenalan Bahasa Isyarat menggunakan teknik *3D-Convolutional Neural Networks* Secara rinci dataset terdiri dari 450 pelatihan, 250 validasi, dan 240 video pengujian yang di dalamnya terdapat total 7754, 3362, dan 2742 instance gesture individu. Dengan metode tersebut pada penelitiannya mendapat nilai akurasi mencapai 95.3% [17].

Penelitian Md. Mehedi Hasan, Azmain Yakin Srizon, Abu Sayeed dan Md. Al Mehedi Hasan dalam International Conference on Computer and Information Technology (ICCIT) ke 23 yang di publikasikan oleh IEEE page 1-9 pada tahun 2020 dengan judul “Classification of American Sign Language by Applying a Transfer Learned Deep Convolutional Neural Network”. Membahas tentang proses klarifikasi ASL menggunakan *Convolutional Neural Networks* (CNN) dengan arsitektur inceptionV3 yang dimodifikasi untuk mendeteksi karakter pada *Amerika Sign Language* pada 36 kelas yang terdiri dari 26 huruf dan 10 angka serta beberapa kali langkah *preprocessing* mendapat nilai akurasi sebesar 98.81% [18].

Penelitian yang dilakukan oleh Darmatasia berjudul “Pengenalan Sistem Isyarat Bahasa Indonesia (SIBI) Menggunakan Gradient-Convolutional Neural Network” dipublikasikan dalam Jurnal INSTEK (Informatika Sains dan Teknologi), Hal. 1-5 no. 26 tahun 2020 membahas tentang pengenalan alfabet SIBI menggunakan algoritma CNN dengan lapisan input diberikan filter *gradient* agar bentuk objek menjadi lebih jelas. Dengan menggunakan lima kelas alfabet SIBI, penelitian tersebut menghasilkan akurasi sebesar 98% [19].

Penelitian Kembuan, Olivia Caren Rorimpandey, Gladly Milian Tompunu Tengker, Soenandar berjudul “Convolutional Neural Network (CNN) for Image Classification of Indonesia Sign Language Using Tensorflow” yang dipublikasikan dalam IEEE Publishing Vol.1028, No.1, Hal.012173 tahun 2020 membahas tentang pengenalan citra BISINDO dengan menggunakan arsitektur *Convolutional Neural Network* (CNN) dan Tensorflow dengan menggunakan 2659 gambar yang terbagi atas 26 kelas alfabet BISINDO menghasilkan akurasi sebesar 96.67% data *training* dan 100% data validasi[20]

Berdasarkan beberapa penelitian yang telah dilakukan sebelumnya dan latar belakang masalah yang ada maka penulis sebagai peneliti bermaksud untuk meneliti tentang penerapan algoritma *Convolutional Neural Network* (CNN) pada klarifikasi Bahasa Isyarat Indonesia (BISINDO) dengan judul “Sistem Klarifikasi Bahasa Isyarat Indonesia (Bisindo) Dengan Menggunakan Algoritma Convolutional Neural Network”.

Dalam penelitian ini di tentukan rumusan masalah bagaimana membangun sebuah rancangan sistem yang mampu mengklarifikasi Bahasa Isyarat Indonesia (BISINDO) menggunakan gambar masukan dengan arsitektur *Convolutional Neural Network* (CNN) sehingga dapat menghasilkan nilai akurasi dengan lebih besar dengan waktu pelatihan lebih cepat dari penelitian-penelitian sebelumnya.

Rancangan sistem yang akan dibangun bahasa pemrograman python dengan model masukan menggunakan dataset BISINDO yang terdiri dari kelas Huruf A-E, Saya, Kamu dan I Love You yang cara pengambilannya memakai kamera web cam. Dataset ini terdiri dari 1734 data pelatihan dan 429 data validasi untuk setiap kelasnya.

Tujuan Penelitian ini adalah mengembangkan sebuah rancangan sistem yang mampu mengklarifikasi model masukan dataset BISINDO menjadi keluaran sesuai kelas masing-masing objek secara langsung menggunakan arsitektur CNN dengan nilai akurasi mencapai 99.82%. Tujuan khusus dari penelitian ini antara lain memberikan alternatif baru untuk penerapan arsitektur CNN dalam sebuah sistem penerjemah bahasa isyarat dengan pelatihan relatif lebih cepat tetapi nilai menghasilkan nilai validasi yang besar.

## II. METODE PENELITIAN

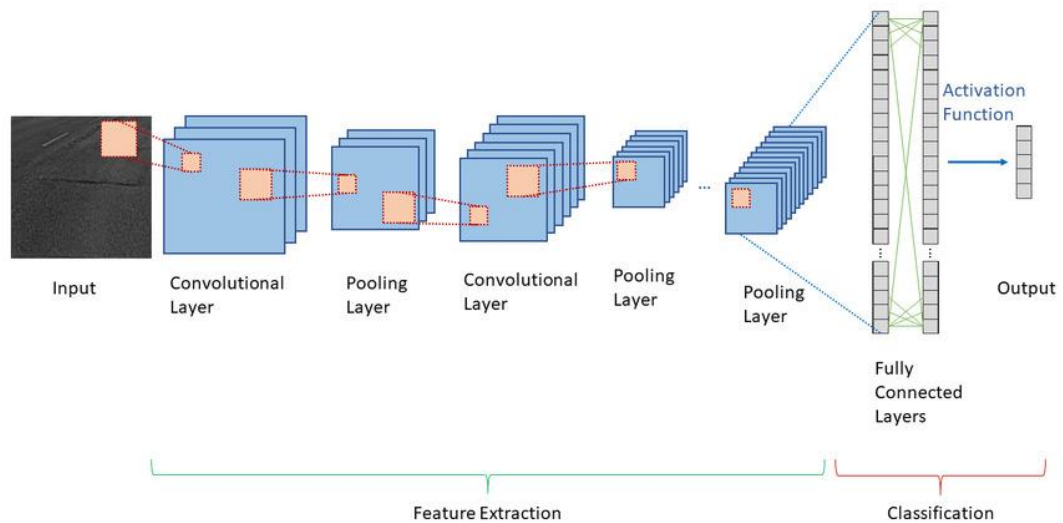
### A. Convolutional Neural Network (CNN)

*Convolutional Neural Network* (CNN) adalah jenis jaringan saraf Multi-lapisan yang sangat khusus. CNN dirancang untuk mengenali pola visual langsung dari gambar dengan pemrosesan minimal. Bidang jaringan saraf pada awalnya terinspirasi oleh tujuan pemodelan sistem saraf biologis, tetapi sejak itu telah bercabang ke arah yang berbeda dan telah menjadi masalah rekayasa dan mencapai hasil yang baik dalam tugas pembelajaran mesin.

Walaupun terlihat sama dengan *Multi-Layer Perceptrons* (MLPs), CNN berkinerja lebih baik daripada *Multi-Layer Perceptrons* (MLPs). Ada dua alasan pertama pada MLP kita mengubah *matriks input* menjadi *vektor numerik* sederhana tanpa struktur spasial sedangkan CNN memahami fakta bahwa piksel gambar yang lebih dekat satu sama lain lebih terkait daripada piksel yang terpisah lebih jauh: CNN = *Input layer* + *hidden layer* + *fully connected layer*

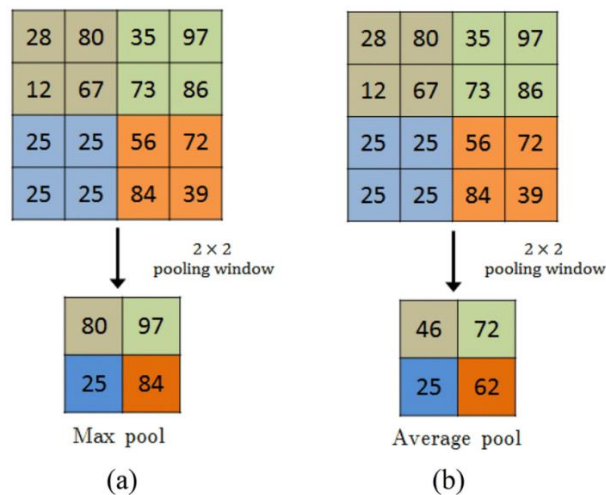
Kedua CNN berbeda dari MLP dalam jenis lapisan tersembunyi yang dapat dimasukkan dalam model. ConvNet mengatur neuronnya dalam tiga dimensi: lebar,

tinggi, dan kedalaman. Setiap lapisan mengubah *volume input* 3D menjadi *volume output* 3D neuron menggunakan fungsi aktivitas[9]. Seperti contoh gambar 2 di bawah ini.




Gambar 2. Arsitektur CNN [10]

*Pooling layer* menyediakan pendekatan untuk *down sampling* peta fitur dengan mengurangi keberadaan fitur di *patch* pada peta fitur khususnya tinggi dan lebar serta untuk menjaga kedalaman. Umumnya terdapat dua metode pooling yaitu *average pooling* dan *max pooling* yang merangkum rata-rata kehadiran fitur dan kehadiran fitur yang paling aktif.[11] *Max Pooling* bekerja lebih baik dalam praktiknya dari pada *average pooling* karena operasi pooling menghitung nilai terbesar di setiap patch dari setiap peta fitur. Hasilnya adalah peta fitur yang di-downsampling atau dikumpulkan akan menyoroti fitur yang paling besar di patch, bukan keberadaan rata-rata fitur, seperti dalam kasus *average pooling*.



Gambar 3. Metode Umum Pooling[12]

Fungsi aktivasi yang biasa di gunakan dalam CNN adalah *ReLU* dan *hard tanh* dan sebagian besar telah menggantikan fungsi aktivasi *sigmoid* dan *soft tanh* di jaringan saraf modern karena kemudahan dalam melatih jaringan saraf berlapis dengan fungsi aktivasi ini[13]. Lapisan *ReLU* akan mengatur semua nilai negatif ke 0 sehingga semua nilai di bawah 0 akan dianggap sebagai 0  $f(x) = \max(0, x)$ [14].



Gambar 4. Fungsi ReLu[14]

### B. TensorFlow

TensorFlow merupakan salah satu antarmuka untuk mengekspresikan algoritma pada pembelajaran mesin dan implementasi untuk mengeksekusi algoritma tersebut. Sistem ini fleksibel dan dapat digunakan untuk berbagai macam algoritma, termasuk algoritma pelatihan dan inferensi di model jaringan saraf dalam. Tensorflow diciptakan oleh tim Google Brain dengan menggunakan bahasa biner C++ yang berperforma tinggi serta dirancang untuk dapat bekerja pada banyak CPU atau GPU dan aplikasi tensorflow dapat di jalankan pada hampir seluruh perangkat termasuk desktop Windows, macOS ataupun Linux dan perangkat seluler baik itu android ataupun iOS[15].

### C. Google Colaboratory


*Colaboratory* adalah *notebook* Jupyter yang dibuat oleh Google untuk membantu berbagi pendidikan dan penelitian *machine learning*. Ini gratis dan berjalan sepenuhnya di *cloud* dan memberikan akses gratis ke sumber daya komputasi termasuk GPU.

Perbedaan dengan Jupyter adalah proyek sumber terbuka yang menjadi basis Colab atau cloud. Colab memungkinkan kita menggunakan dan berbagi *notebook* Jupyter dengan orang lain tanpa harus mengunduh, menginstal, atau menjalankan apa pun[16].

### D. Metodologi Penelitian

Manuskrip penelitian ini akan menggunakan beberapa tahapan seperti studi literatur untuk melihat apakah sudah ada penelitian sejenis serta mengobservasi penelitian tersebut untuk menganalisis kelemahan serta kekurangan penelitian sebelumnya.


Setelah tahapan studi literatur, penelitian ini akan masuk ke empat tahap berikutnya seperti yang dapat di lihat pada gambar 1.



Gambar 5. Metodologi Penelitian

### E. Pengumpulan Dataset

Metode pengumpulan data penelitian akan menggunakan teknik observasi di mana dalam proses ini bentuk tangan akan didokumentasikan dalam bentuk gambar RGB (*Red Green Blue*) dengan format PNG dan menghasilkan data primer. Contoh pengambilan dataset ditunjukkan pada gambar 6.



Gambar 6. Pengambilan dataset

Dataset ini berisi 2163 gambar dengan 9 kelas dengan ukuran dataset 52,1 MB dan menggunakan latar belakang hijau dan putih. Dari 2163 gambar tersebut, kami menggunakan 1734 gambar (80%) sebagai dataset pelatihan, dan 429 gambar (20%) digunakan untuk dataset validasi. Contoh dataset ditunjukkan pada gambar 7.



Gambar 7. Contoh gambar dataset

## F. Data Preprocessing

Pada tahap ini 2163 gambar yang terdiri dari 9 kelas pada dataset di unggah ke penyimpanan google drive dan di masukan ke google colab untuk di proses. Setelah dataset terimpor di google colab, kami menggunakan *module Image Data Generator* pada *library Keras* untuk melakukan data augmentasi dengan parameter sebagai berikut

- *rescale = 1./255,*
- *rotation\_range=40,*
- *width\_shift\_range=0.2,*
- *height\_shift\_range=0.2,*
- *shear\_range=0.2,*
- *zoom\_range=0.2,*
- *horizontal\_flip=True,*
- *fill\_mode='nearest',*

Dan menggunakan parameter *validation\_split=0.2* untuk membagi dataset dengan rasio 80% atau 1734 gambar sebagai data pelatihan dan 20% atau 429 gambar sebagai data validasi serta 2163 gambar sebagai data tes sehingga kami tidak perlu untuk memisahkan data pelatihan dan data validasi secara manual.

Setelah dataset terbagi, selanjutnya adalah pelabelan data di mana setiap kelas dengan gambar yang sama akan diberi label yang sama. Setelah itu dengan menggunakan metode *flow\_from\_directory()*, sistem akan mengambil jalur direktori untuk membaca gambar dari array numpy sesuai label yang sudah kita buat dengan parameter di *training generator* maupun validasi generator sebagai berikut *color\_mode='rgb'*, *batch\_size=32*, *shuffle=True* dengan pembeda antara training dan validasi di subset dari data.

Selanjutnya kita mengatur resolusi atau ukuran gambar masukan untuk model menjadi 256x256 piksel dengan `target_size=(256,256)`, ukuran ini adalah ukuran terbaik untuk gambar masukan pada *deep learning* saat dataset di latih[21], [22].

### G. Modeling

Arsitektur pada jurnal ini menggunakan Convolutional Neural Network (CNN) dengan model Sequential Model yang dibuat ditunjukkan pada gambar 8.

Model: "sequential"

Layer (type)	Output Shape	Param #
Conv2D_1 (Conv2D)	(None, 253, 253, 32)	896
Pool_1 (MaxPooling2D)	(None, 126, 126, 32)	0
Conv2D_2 (Conv2D)	(None, 124, 124, 64)	18496
Pool_2 (MaxPooling2D)	(None, 62, 62, 64)	0
Conv2D_3 (Conv2D)	(None, 60, 60, 64)	36928
Pool_3 (MaxPooling2D)	(None, 30, 30, 64)	0
Conv2D_4 (Conv2D)	(None, 28, 28, 128)	73856
Pool_4 (MaxPooling2D)	(None, 9, 9, 128)	0
Conv2D_5 (Conv2D)	(None, 7, 7, 256)	295168
Pool_5 (MaxPooling2D)	(None, 3, 3, 256)	0
Neuron_Drop5 (Dropout)	(None, 3, 3, 256)	0
Input_Hidd_layer (Flatten)	(None, 2304)	0
Hidd_layer1 (Dense)	(None, 176)	405680
Drop_Hidden1 (Dropout)	(None, 176)	0
Hidd_layer2 (Dense)	(None, 81)	14337
Drop_Hidden2 (Dropout)	(None, 81)	0
Hidd_layer3 (Dense)	(None, 27)	2214
Drop_Hidden3 (Dropout)	(None, 27)	0
Output_Hidd_layer (Dense)	(None, 9)	252
Total params: 847,827		
Trainable params: 847,827		
Non-trainable params: 0		

Gambar 8. Arsitektur Model CNN

Pada model pelatihan terdapat lima layer konvolusi dengan aktivasi relu, lima *Max Pooling*, tiga *Dropout* untuk mengurangi *overfitting*[23], tiga hidden layer dengan neuron hidden layer pertama 176 *node*, neuron hidden layer kedua 81 *node* dan neuron hidden ketiga 27 *node* untuk mendapatkan hasil terbaik saat pelatihan[24], sembilan output



sesuai kelas dengan aktivasi model keluaran *Softmax* serta Model di-compile menggunakan Adam *optimizer*.

## H. Training Model

Training model merupakan proses di mana model yang telah kita buat sebelumnya dilatih untuk mencari dan mempelajari serta menyesuaikan bobot dan bias terbaik ke algoritme dengan tujuan meminimalkan fungsi kerugian pada rentang prediksi. Pada penelitian ini training model menggunakan google colaboratory dengan parameter seperti gambar 9.

```
STEP_SIZE_TRAIN=train_gen.n//train_gen.batch_size
STEP_SIZE_VALID=val_gen.n//val_gen.batch_size

history = model.fit(
    train_gen,
    steps_per_epoch = STEP_SIZE_TRAIN,
    epochs = train_gen.n,
    validation_data = val_gen,
    validation_steps = STEP_SIZE_VALID,
    verbose =1,
    callbacks=[callbacks]
)
```

Gambar 9. Parameter Training Model

Pada penelitian ini parameter model ditraining dengan 1734 *epoch* dengan 54 *steps* setiap epochnya untuk mengurangi *underfitting*. Training model juga menggunakan *callback* yang merupakan *subclass* dari keras dengan kondisi di mana jika akurasi data sudah mencapai nilai tertentu maka proses training di hentikan untuk menghindari *overfitting* pada training model.

## III. HASIL DAN PEMBAHASAN

Dataset yang diambil dengan teknik observasi di mana bentuk tangan didokumentasikan menjadi gambar RGB (*Red Green Blue*) dengan format PNG dan menghasilkan data primer sebanyak 2163 gambar BISINDO yang terbagi menjadi lima kelas gambar.

Selanjutnya dataset diberi label untuk setiap kelas dan dibagi menjadi dua yaitu data train dan data validasi, setelah data dibagi kita membuat model pelatihan dan menghasilkan *Total params: 847,827*, *Trainable params: 847,827* dan *Non-trainable params: 0*.

### A. Perbandingan Dengan Penelitian Sebelumnya Yang Menggunakan Algoritma CNN

Penelitian ini menggunakan gambar masukan 256x256 piksel serta ditraining dengan 1734 *epoch* di mana setiap epochnya menggunakan 54 *steps* dan diberi subclass *callback* dari Keras untuk menghentikan training agar tidak *overfitting*, menunjukkan performa antara algoritma CNN yang diusulkan peneliti dengan algoritma CNN yang digunakan pada beberapa penelitian BISINDO sebelumnya, metode CNN peneliti bekerja lebih optimal dari CNN pada penelitian BISINDO sebelumnya sekitar 1.82% - 3.82% pada bagian *accuracy* sebesar 99.82% seperti yang ditunjukkan pada Tabel 1.



Tabel 1.  
Perbandingan Penelitian Sebelumnya Dengan Metode CNN

Method	Input Size	Accuracy (%)
BISINDO_CNN	256x256	99.82%
SIBI_CNN_ Darmatasia[19]	28x28	98%
BISINDO_CNN_ Kembuan[20]	150x150	96.67%
BISINDO_CNN_Andi[25]	100x90	96%

### B. Training Dataset


Model yang dilatih dengan 1734 epoch di mana setiap epochnya menggunakan 54 *steps* pada dataset BISINDO peneliti menggunakan gambar masukan 256x256 piksel menghasilkan *Accuracy* = 99.82% dan *Evaluation Accuracy* = 100.00% seperti gambar 10.

Accuracy = 99.82%  
 Evaluation Accuracy = 100.00%  
 Loss = 1.01%  
 Evaluation Loss = 0.15%

Gambar 10. Hasil Training Data

### C. Training and Validation Accuracy


Pelatihan pada epoch terakhir dihentikan dengan *callback* dan menghasilkan *Evaluation Accuracy* berakhir 100.00% serta *Accuracy* 99.82% untuk dataset pelatihan. Keakuratan untuk *Training* dan *Validation Accuracy* dapat ditunjukkan pada Gambar 11.



Gambar 11. Keakuratan untuk set pelatihan dan set validasi

### D. Training and Validation Loss

Pelatihan pada *epoch* terakhir dihentikan dengan *callback* dan menghasilkan *Evaluation Loss* berakhir 0.15% serta Loss 1.01% untuk dataset pelatihan. Penurunan untuk *Training* dan *Validation Loss* dapat ditunjukkan pada Gambar 12.



Gambar 11. Keakuratan untuk set pelatihan dan set validasi

### E. Prediction Test

Model akurasi Klasifikasi Gambar CNN untuk Bahasa Isyarat Indonesia telah mencapai 99.82%. Pada tahap klarifikasi citra sebagai tahap akhir dari sistem ini, peneliti menggunakan metode Keras *predict* yang merupakan subclass dari Keras *library* untuk melakukan analisa menyeluruh terhadap gambar di setiap kelas dataset sehingga lebih efisien[26]. Setelah dataset selesai di prediksi, hasil prediksi di simpan dalam *file results* dengan format *csv*. Contoh hasil prediksi ditunjukkan pada gambar 12.

Filename	Predictions
A/A (1).jpg	A
A/A (10).jpg	A
A/A (100).jpg	A
A/A (101).jpg	A
A/A (102).jpg	A
A/A (103).jpg	A
A/A (104).jpg	A
A/A (105).jpg	A

Gambar 12. Hasil Prediksi Dataset

Hasil prediksi menunjukkan dari 2163 gambar hanya ada satu gambar pada kelas I Love You yang tidak berhasil di prediksi dengan baik seperti yang di tunjukan pada gambar 13.

1517	I Love You/ILoveYou (6).jpg	I Love You
1518	I Love You/ILoveYou (60).jpg	L
1519	I Love You/ILoveYou (61).jpg	I Love You

Gambar 13. Tidak Berhasil Memprediksi Gambar

## IV. KESIMPULAN

Sistem klarifikasi bahasa isyarat Indonesia (BISINDO) dengan menggunakan algoritma *convolutional neural network* dan masukan gambar 256x256 piksel, dapat disimpulkan model yang dibuat peneliti bisa memprediksi gambar pada setiap kelas dengan sangat baik dan menghasilkan akurasi sebesar 99,82%, terbukti hanya satu gambar pada kelas I Love You yang tidak berhasil dengan baik. Hal ini dikarenakan pada nilai akurasi tidak mencapai 100% karena bisa menyebabkan *overfitting* pada *training data*.

Penelitian ini tentunya masih memiliki keterbatasan yaitu hanya 9 kelas data BISINDO saja. Pengembangan yang dapat dilakukan pada penelitian selanjutnya yaitu metode dalam pengambilan dataset dapat di evaluasi kembali dengan menggunakan 26 alfabet dan beberapa kata dalam BISINDO melalui pengambilan data dengan para ahli penerjemah bahasa isyarat. Selain itu, pada penelitian ini hanya memprediksi gambar yang sudah menjadi masukan awal, sehingga pada penelitian selanjutnya dapat dipertimbangkan untuk membuat sistem pengenalan BISINDO secara *real time*.

## UCAPAN TERIMA KASIH

Peneliti berterima kasih pada Bapak Barka Satya, M.Kom. karena berkat bimbingan peneliti dapat menyelesaikan jurnal. Peneliti juga berterima kasih pada orang tua dan keluarga penulis yang selalu mendukung dan menyemangati dari segala aspek mulai dari mental hingga keuangan. Tak lupa, peneliti berterima kasih pada kekasih tercinta peneliti yang menyemangati dan selalu berjuang bersama dalam suka maupun duka.

## DAFTAR PUSTAKA

- [1] B. D. Ruben and L. Stewart, *Communication and Human Behavior*. Pearson/Allyn & Bacon, 2006. [Online]. Available: <https://books.google.co.id/books?id=PEVLPgAACAAJ>
- [2] L. Komala, *Ilmu komunikasi : perspektif, proses, dan konteks*, 1st ed. Bandung: [Bandung]: Widya Padjadjaran, 2009. [Online]. Available: [http://lib-fikom.yai.ac.id/index.php?p=show\\_detail&id=4370](http://lib-fikom.yai.ac.id/index.php?p=show_detail&id=4370)
- [3] K. Sosial, “Sistem Informasi Management Penyandang Disabilitas,” *Kementerian Sosial Republik Indonesia*, 2022. <https://simpd.kemensos.go.id/> (accessed Mar. 24, 2022).
- [4] Kemendikbud, “Kamus SIBI,” *Lembaga Penelitian dan Pengembangan Sistem Isyarat Bahasa Indonesia*, 2020. <https://pmpk.kemdikbud.go.id/sibi/> (accessed Mar. 28, 2022).
- [5] M. Susanty, R. Z. Fadillah, and A. Irawan, “Model Penerjemah Bahasa Isyarat Indonesia (BISINDO) Menggunakan Pendekatan Transfer Learning,” *PETIR*, vol. 15, no. 1, pp. 1–9, Dec. 2021, doi: 10.33322/petir.v15i1.1289.
- [6] P. B. I. Indonesia, “Asal Usul BISINDO dan PUSBISINDO,” 2009. <https://pusbisindo.org/tentang-kami> (accessed Apr. 30, 2022).
- [7] Srisaan Ploychompu, “Good signs: Japan’s APU graduate creates successful deaf cafe in Indonesia | Japan Subculture Research Center,” Aug. 07, 2017. <http://www.japansubculture.com/good-signs-japans-apu-graduate-creates-successful-deaf-cafe-in-indonesia/> (accessed Aug. 14, 2022).
- [8] R. A. Mursita, “RESPON TUNARUNGU TERHADAP PENGGUNAAN SISTEM BAHASA ISYARAT INDONESIA (SIBI) DAN BAHASA ISYARAT INDONESIA (BISINDO) DALAM KOMUNIKASI,” *INKLUSI*, vol. 2, no. 2, p. 221, Dec. 2015, doi: 10.14421/ijds.2202.
- [9] M. Sewak, R. Karim, and P. Pujari, *Practical Convolutional Neural Networks*. 2018.
- [10] D. Arya *et al.*, “Transfer Learning-based Road Damage Detection for Multiple Countries,” pp. 1–16, Aug. 2020, Accessed: Aug. 18, 2022. [Online]. Available: <http://arxiv.org/abs/2008.13101>
- [11] J. Brownlee, “Deep Learning for Computer Vision Image Classification , Object Detection , and Face Recognition in Python UNLOCK Computer Vision With Deep Learning,” *Deep Learn. Comput. Vis.*, pp. 1–21, 2019, [Online]. Available: <https://machinelearningmastery.com/deep-learning-for-computer-vision/>
- [12] P. Ahamed, S. Kundu, T. Khan, V. Bhateja, R. Sarkar, and A. F. Mollah, “Handwritten Arabic numerals recognition using convolutional neural network,”

- J. Ambient Intell. Humaniz. Comput.*, vol. 11, no. 11, pp. 5445–5457, Nov. 2020, doi: 10.1007/s12652-020-01901-7.
- [13] C. C. Aggarwal, *Neural Networks and Deep Learning*. Cham: Springer International Publishing, 2018. doi: 10.1007/978-3-319-94463-0.
  - [14] J. Wu, “Introduction to Convolutional Neural Networks,” in *Introduction to Convolutional Neural Networks*, 2017, pp. 1–31. [Online]. Available: [https://web.archive.org/web/20180928011532/https://cs.nju.edu.cn/wujx/teaching/15\\_CNN.pdf](https://web.archive.org/web/20180928011532/https://cs.nju.edu.cn/wujx/teaching/15_CNN.pdf)
  - [15] T. Developers, “TensorFlow,” May 2022, doi: 10.5281/ZENODO.6574269.
  - [16] “About Colaboratory - ML EDU Help.” [https://support.google.com/machinelearningeducation/answer/7656404?hl=en&ref\\_topic=7654357](https://support.google.com/machinelearningeducation/answer/7656404?hl=en&ref_topic=7654357) (accessed Aug. 23, 2022).
  - [17] J. Huang, W. Zhou, H. Li, and W. Li, “Attention-Based 3D-CNNs for Large-Vocabulary Sign Language Recognition,” *IEEE Trans. Circuits Syst. Video Technol.*, vol. 29, no. 9, pp. 2822–2832, Sep. 2019, doi: 10.1109/TCSVT.2018.2870740.
  - [18] M. M. Hasan, A. Y. Srizon, A. Sayeed, and M. A. M. Hasan, “Classification of American Sign Language by Applying a Transfer Learned Deep Convolutional Neural Network,” in *2020 23rd International Conference on Computer and Information Technology (ICCIT)*, Dec. 2020, pp. 1–6. doi: 10.1109/ICCIT51783.2020.9392703.
  - [19] D. DARMATASIA, “PENGENALAN SISTEM ISYARAT BAHASA INDONESIA (SIBI) MENGGUNAKAN GRADIENT-CONVOLUTIONAL NEURAL NETWORK,” *J. INSTEK (Informatika Sains dan Teknol.*, vol. 6, no. 1, p. 56, Jan. 2021, doi: 10.24252/instek.v6i1.18637.
  - [20] O. Kembuan, G. Caren Rorimpandey, and S. Milian Tompunu Tengker, “Convolutional Neural Network (CNN) for Image Classification of Indonesia Sign Language Using Tensorflow,” in *2020 2nd International Conference on Cybernetics and Intelligent System (ICORIS)*, Oct. 2020, no. 26, pp. 1–5. doi: 10.1109/ICORIS50180.2020.9320810.
  - [21] O. Rukundo, “Effects of Image Size on Deep Learning,” no. August, Jan. 2021, [Online]. Available: <http://arxiv.org/abs/2101.11508>
  - [22] O. Rukundo, “EFFECTS OF IMAGE SIZE ON DEEP LEARNING Olivier Rukundo Department of Clinical Physiology, Lund University”, doi: <https://doi.org/10.48550/arXiv.2101.11508>.
  - [23] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, “Dropout: A simple way to prevent neural networks from overfitting,” *J. Mach. Learn. Res.*, vol. 15, pp. 1929–1958, 2014.
  - [24] D. Stathakis, “How many hidden layers and nodes?,” *Int. J. Remote Sens.*, vol. 30, no. 8, pp. 2133–2147, 2009, doi: 10.1080/01431160802549278.
  - [25] S. Andi Aljabar, A. Aljabar, and S. Suharjito, “BISINDO ( Bahasa Isyarat Indonesia ) Sign Language Recognition Using CNN and LSTM,” *Adv. Sci. Technol. Eng. Syst. J.*, vol. 5, no. 5, pp. 282–287, 2020, doi: 10.25046/aj050535.
  - [26] “Keras predict | What is Keras predict with Examples?” <https://www.educba.com/keras-predict/> (accessed Oct. 29, 2022).